Kelompok A2:

1. Hana Mardiyah
2. Imam Miftahul Ulum
3. Iryansyah Jaya
4. Luthfiah Nur Azizah
5. Salwa Zaida Nasrullah

PENJELASAN SINGKAT TUGAS

1. **Definisi**

Web scraping atau disebut juga web data mining atau web
harvesting adalah proses mengekstrak, memisahkan, mengunduh,
dan mengorganisasikan informasi pada satu atau lebih website secara otomatis. Dal
am tugas ini, kelompok kami menggunakan Selenium dan PyQt yang disesuaikan de
ngan ketentuan tugas juga dikarenakan mampu menangani website dinamis.

2. **Arsitektur Selenium**

Arsitektur WebDriver terdiri dari tiga komponen utama, yaitu:

a. Python
   Script menjadi kode utama yang berisi instruksi hal apa yang ingin diambil.
b. Driver (edgedriver) menjadi jembatan untuk menerjemah antara Python dan Browser.
c. Web Browser (Microsoft Edge) menjadi tempat data
   yang akan dieksekusi berada secara otomatis.

3. **Arsitektur Framework GUI (PyQt6)**

Berikut adalah karakteristik utama PyQt6:

a. Signal yang merupakan pemberitahuan bahwa suatu aksi terjadi (seperti klik t
   ombol) dan Slot adalah fungsi yang menangani aksi tersebut.
b. Event Loop yang menjalankan *infinite loop*)
   di latar belakang. Sistem ini berfungsi untuk "mendengarkan" setiap input dari
   user (klik, ketik, geser) secara *real-time* agar aplikasi selalu responsif.
c. *Layout*
   Manager (QVBoxLayout, QHBoxLayout) yang memungkinkan posisi tombol,
   input,
   dan tabel menyesuaikan diri secara otomatis (proporsional) saat jendela aplik
   asi diubah ukurannya oleh user.

d. Object-Oriented
(Berbasis Objek) untuk memudahkan dalam mengatur properti (warna atau te ks)
dan fungsi setiap elemen secara spesifik tanpa mengganggu elemen lainnya.

4. **Alur Proses Scraping**

Berikut Langkah-langkah teknis scraping:

a. Inisialisasi dan akses URL

Program dimulai dengan memanggil driver browser
(Edge). Perintah driver.get(url) dikirimkan, lalu driver akan membuka browser
dan memuat halaman url yang diinginkan. Program
juga harus menunggu sampai seluruh elemen HTML selesai dimuat.

b. Inspeksi Document Object Model

Sebelum proses ekstraksi dilakukan, tahap inspeksi elemen dilakukan untuk memeta kan struktur hierarki HTML pada situs yang diinginkan.
Langkah ini sangat penting untuk menemukan alamat unik (lokator) dari data
yang diinginkan. Dalam aplikasi ini, digunakan Multi-Locator
Strategy untuk menjamin data tetap terambil meskipun struktur halaman berubah. M etode-metode lokator yang diimplementasikan antara lain:

- By.TAG_NAME yang digunakan untuk mengidentifikasi kontainer utama <artic le> sebagai pembungkus entitas berita dan tag
  <a> untuk menangkap atribut *Hyperlink Reference* (href).
- By.CLASS_NAME yang berfungsi sebagai *fallback* (cadangan) menggunakan *class* list-
  content__item apabila situs tidak menerapkan tag standar <article>.
- By.XPATH yang digunakan untuk melakukan inspeksi mendalam pada bagian <head> HTML. Teknik ini menyasar Meta
  Tags untuk mendapatkan data judul dan ringkasan yang lebih bersih dibandin gkan teks visual di layar.
- By.CSS_SELECTOR yang diimplementasikan pada fungsi _extract_date untu k memindai elemen visual spesifik seperti .detail__date,
  .media__date, atau .time.
- By.PARTIAL_LINK_TEXT yang digunakan khusus pada alur Pagination untuk mendeteksi keberadaan elemen navigasi agar
  program dapat berpindah halaman secara otomatis.

c. Ekstraksi data atau looping

Setelah struktur DOM selesai dipetakan, sistem melakukan ekstraksi data secara sis tematis. Langkah-langkah ekstraksi Adalah sebagai berikut:

- Sistem menyisir halaman daftar berita untuk mencari semua elemen.
  Dari setiap elemen tersebut, program mengekstraksi atribut href dari tag <a>. link-
  link inidisimpan dalam sebuah daftar untuk diproses dalam tahap berikutnya.
- Program menggunakan perintah driver.execute_script untuk membuka setiap link berita di tab baru (_blank).
  Hal ini dilakukan agar halaman utama (daftar berita) tidak hilang dan proses scraping tidak perlu melakukan *reload* berulang kali. Serta switching
  context untuk berpindah fokus dari tab utama ke tab berita menggunakan driver.switch_to.window.
- Pengambilan informasi spesifik seperti judul yang diambil dari meta property='og:title'
  agar mendapatkan judul yang bersih, isi berita yang diambil dari meta property='og:description' sebagai ringkasan berita yang efisien, serta tanggal publikasi yang menggunakan fungsi _extract_date.
- Data yang berhasil ditarik kemudian melalui proses normalisasi.
  String tanggal yang didapat dari DOM diubah menjadi objek datetime Python. Jika tanggal berita tidak masuk dalam rentang "Dari" dan "Sampai" yang diinput user di
  GUI, maka data tersebut akan dibuang dan tidak dimasukkan ke hasil akhir.

Setelah data satu berita berhasil diambil,
program akan menjalankan driver.close() untuk menutup tab berita tersebut dan kembali ke tab utama (driver.switch_to.window(driver.window_handles[0])) untuk melanjutkan ke link berikutnya. Proses ini terus berulang hingga seluruh link
di halaman tersebut selesai diproses. Pada tahap ini juga terhubung Progress Bar di GUI, di
mana setiap satu berita selesai diekstraksi, sinyal progress_signal akan dikirimkan untuk memperbarui tampilan persen di aplikasi.

5. **Pagination (Navigasi Halaman)**

Jika berita atau data ada di banyak halaman, alur proses
yang akan terjadi Adalah sebagai berikut:

a. Program mencari tombol "Next" atau angka halaman berikutnya.
b. Jika sudah ditemukan, program akan melakukan perintah .click().
c. Program kembali ke alur ekstrasi data di halaman baru tersebut.
d. Jika tombol "Next" sudah tidak ada (NoSuchElementException), *looping* berhenti.

6. **Penyimpanan Data (Export Data)**

Pengubahan data
yang ada di memori Python menjadi file fisik sesuai dengan ketentuan tugas, yaitu:

a. Format
   JSON/CSV yang menggunakan library json atau pandas untuk mengubah ku mpulan data tadi menjadi tabel atau struktur teks yang rapi.

b. File
   Gambar, hanya dilakukan jika scraping gambar, menggunakan library urllib.re quest untuk mendownload file gambar langsung ke folder lokal.